

SEMANA 06 · EDA & MODEL SELECTION

DepaRent

Análisis Exploratorio de Datos y Selección de Modelos para una
plataforma inteligente de valoración de alquileres en Lima Metropolitana

DS3022 — Desarrollo de Producto de Datos | Prof. Carlos Domínguez


Adrian Urbina Mendoza · Armando Martinez Palomino · Breysi Salazar Medina · Luciana Yangali Cáceres

Planteamiento del Problema

¿Cómo sabe un propietario cuánto pedir por su departamento?

Fijar el precio de alquiler implica considerar simultáneamente múltiples variables: ubicación, tamaño, dormitorios, baños, amenidades y el comportamiento dinámico del mercado.

"Tengo un departamento de 70 m² en Lince, con dos dormitorios, dos baños y cochera. ¿Debería publicarlo a S/ 2,400, S/ 2,700 o S/ 3,000?"



¿Por qué este análisis y por qué ahora?

EL PROBLEMA DEL PRODUCTO

¿Cómo determina un propietario un precio de alquiler razonable, sin una herramienta que compare su inmueble contra el mercado real?

DepaRent busca reducir esa incertidumbre estimando, comparando y recomendando precios sobre la base de datos reales del mercado limeño.

EL VÍNCULO CON EL EDA

Los 6 componentes de DepaRent (segmentación, accesibilidad, predicción de precio, tendencia distrital, recomendación y simulador) solo son tan buenos como los datos que los alimentan.

OBJETIVO DE ESTA ENTREGA

Verificar si los datos disponibles son suficientes y confiables para entrenar los 6 modelos analíticos del producto.

- ¿Qué tan completos y confiables son los datos crudos? *Sección 2-4*
- ¿Qué errores esconden los precios y categorías extremas? *Sección 5*
- ¿Qué patrones de mercado ya son visibles sin modelar? *Sección 6-8*
- ¿Con qué limitaciones debe convivir el producto final? *Sección 9*

Tres fuentes de datos, un solo producto

3,822

43 columnas

Departamentos

Adondevivir + Urbania

Anuncios individuales de alquiler en Lima Metropolitana y Callao. Incluye texto libre para recuperación de amenidades y piso.

663

6 columnas

Panel BCRP

Banco Central de Reserva

Series trimestrales de PER, precio de venta USD/m² y alquiler implícito, por distrito (T3-2013 a T1-2026).

3,233

10 columnas

Paraderos ATU

Autoridad de Transporte Urbano

Inventario oficial de paraderos georreferenciados: tipo de transporte y nivel de afluencia (corte mayo 2021).

Flujo de trabajo del EDA



Cada paso queda documentado con evidencia real (números, tablas y hallazgos) dentro del propio notebook — no solo como código, sino como narrativa reproducible.

17 columnas llegan 100% vacías — y eso es correcto

17

columnas 100% nulas en el dataset
crudo

Amenidades (piscina, gimnasio, ascensor...), piso, estado del inmueble y nombre de proyecto llegan sin dato estructurado.

HALLAZGO VERIFICADO

Se investigó directamente el JSON de origen (`__PRELOADED_STATE__`) del portal. El backend no expone amenidades ni número de piso como campos estructurados para anuncios individuales de alquiler — solo existen 7 códigos estructurados (área, dormitorios, baños, antigüedad, estacionamientos).

Es una limitación de la fuente, no un error del scraper — la decisión de diseño fue preservar estos campos como vacíos y recuperar lo posible desde el texto libre en la siguiente etapa.

ascensor · balcon · terraza · piscina · gimnasio · deposito · vista_al_mar · parrilla · areas_verdes · seguridad_24_7 · coworking · juegos_infantiles · pet_friendly · piso · estado_inmueble · nombre_proyecto · características

Recuperando información atrapada en el texto

Se aplicaron expresiones regulares sobre el texto libre (título + descripción + características) para rescatar variables sin campo estructurado.

Variable	Recuperados	Cobertura	Criterio
piso	2,098	54.89%	Patrones de nivel/piso (rango válido 1–45)
antigüedad	521	13.63%	Años declarados o mención de 'estreno' (=0)
estacionamientos	197	5.15%	Cocheras mencionadas explícitamente
mantenimiento	43	1.13%	Cuotas en soles (rango S/50–S/2,500)

NOTA METODOLÓGICA — estacionamientos

Solo el 10.75% de los nulos se confirma por texto como 'sin cochera'. El 89.25% restante es ambiguo — no se imputa a 0, se preserva como dato faltante con flag propio.

14 AMENIDADES EXTRAÍDAS POR PALABRAS CLAVE

seguridad_24_7	44.6%
parrilla	37.6%
ascensor	36.1%
gimnasio	33.0%
balcon	31.9%
coworking	30.3%
piscina	27.2%
pet_friendly	26.7%
juegos_infantiles	8.7%

El caso de los S/ 10.5 millones de alquiler

Antes del filtro, precio_soles llegaba a S/ 10,500,000 — imposible como renta mensual. ¿Error o segmento premium legítimo?

1

Filtro estadístico

Se acota precio_soles a [S/800, S/25,000] — percentil 96.02 de la distribución observada.

2

Inspección manual

Los 15 casos más extremos resultaron ser títulos como 'Vendo/alquilo Penthouse... S/10,500,000' — el precio capturado era de VENTA, no de alquiler.

3

Verificación oculta

127 anuncios de doble modalidad venta/alquiler. De ellos, 40 tenían un precio de venta que caía por casualidad $\leq$ S/25,000 — invisibles para el filtro de precio.

4

Decisión final

Se excluyen los 127 anuncios por título (venta/vendo/se vende), no solo por monto — el precio no es confiable sin importar su magnitud.

694

filas descartadas (18.16%)

127

por doble modalidad venta/alquiler

40

casos ocultos al filtro de precio

3,128

departamentos en df_clean final

Quando un typo casi arruina el modelo

"BARRANCA" → "BARRANCO"

Barranco es un distrito real de Lima. Barranca es una provincia a más de 180 km al norte — fuera del área del proyecto.

1 anuncio con distrito = "Barranca" (id 150601693)

Coordenadas reales: (-12.1189, -77.0337)

→ ubicadas exactamente en el malecón de Barranco, Lima.

Como el anuncio ya había superado el filtro geográfico de Lima, sus coordenadas confirman que se trata de un error de tipeo — no de un anuncio real de otra provincia. Corrección con evidencia, no por suposición.

211 → 212

anuncios en Barranco

DISTRITOS CON MUESTRA INSUFICIENTE

19 distritos con menos de 20 anuncios se agrupan en la categoría "Otros".

125

filas agrupadas (4.00% de df_clean)

19

distritos con <20 observaciones

¿Por qué importa?

Sin agrupar, una categoría de 19 filas ('Punta Hermosa') apareció en el top 3 de variables más influyentes del modelo de precio — un artefacto de sobreajuste, no un patrón de mercado real. Al agruparlas, el feature importance quedó dominado por variables con soporte estadístico genuino.

Retos y limitaciones que el producto debe asumir



Ambigüedad en estacionamientos

89.25% de los nulos no se puede confirmar como "sin cochera" — es dato no informado, no ausencia real.

Riesgo: el modelo de precio puede subestimar el efecto de la cochera en ese segmento.



Contexto BCRP incompleto

16.3% de los departamentos no tiene serie distrital propia y usa el 'Promedio general' metropolitano.

Riesgo: menor precisión de tendencia de mercado para esos distritos.



Paraderos con corte a 2021

El inventario oficial de la ATU no se actualiza desde mayo 2021.

Riesgo: nueva infraestructura de transporte no queda reflejada en accesibilidad.






Dependencia de texto libre

Amenidades y piso se infieren por palabras clave, no por campo estructurado del portal.

Riesgo: sinónimos no contemplados generan falsos negativos en amenidades.

El filtro de calidad transformó la distribución de precios



14.07 → 3.24

reducción de asimetría (skewness) tras el filtro



S/ 2,750

mediana de alquiler mensual en df_clean

Miraflores / San Isidro


distritos con mayor dispersión de precio (colas de outliers de lujo)

Qué variables realmente explican el precio



mantenimiento ($r=0.79$) y *area_total* ($r=0.77$) son los predictores lineales más fuertes — pero el Random Forest revela que la accesibilidad al transporte (*dist_paradero_min_m*, *dist_troncal_brt_m*) también pesa, algo que una correlación simple no captura.

El mercado sube, y el transporte lo explica en parte



ACCESIBILIDAD AL TRANSPORTE (ATU)

174.8 m

distancia mediana al paradero más cercano

71.6%


de los departamentos a menos de 300 m de un paradero

9.3

paraderos promedio en radio de 500 m

83.7% de los departamentos se enlaza a su serie distrital propia del BCRP; el 16.3% restante usa el promedio metropolitano (trimestre de referencia: 2026-T1). La tendencia histórica muestra un alquiler al alza en casi todos los distritos analizados, con oscilación trimestral regular.

Perfiles que emergen del mercado de alquiler



- **Cluster 0 (49.01%):** *Estándar tradicional* con propiedades de tamaño medio, aproximadamente 2 dormitorios y baja presencia de amenidades.
- **Cluster 1 (14.54%):** *Propiedades amplias* que destacan por un área promedio de 188.82 m², mayor cantidad de dormitorios y baños y mayor mantenimiento.
- **Cluster 2 (27.99%):** *Compacto con alta oferta de amenidades* con propiedades pequeñas y relativamente nuevas.
- **Cluster 3 (8.46%):** *Residencial familiar* con propiedades relativamente nuevas con alta presencia de amenidades.

Entregables y próximos pasos

✓	DataAnalysis.md	Documentación completa del EDA con evidencia y decisiones justificadas
✓	ModelSelection.md	Selección de los 6 modelos con métricas reales
✓	Notebook Colab	Ordenado, comentado, con 'hallazgos' documentados paso a paso
✓	data/processed/	5 datasets limpios e integrados, listos para modelar

MODELO GANADOR (PREDICCIÓN DE PRECIO)

HistGB

HistGradientBoosting Regressor

15.93%

MAPE en test (56.5% mejor que el baseline)

0.8236

R² sobre el conjunto de prueba (20%
holdout)