

Delivery 1 – Integrated Project Definition

1. Resumen ejecutivo

DepaRent es una plataforma web de apoyo a la decisión dirigida principalmente a propietarios que desean publicar uno o varios departamentos en alquiler en Lima Metropolitana y Callao. El producto aborda la incertidumbre que enfrenta el propietario al comparar su inmueble con el mercado, estimar un precio razonable y definir una estrategia de publicación sustentada en datos.

La primera fase consolidó tres capas analíticas. La capa descriptiva caracteriza el perfil competitivo del inmueble y su accesibilidad urbana; la capa predictiva estima el precio esperado de alquiler y la tendencia distrital; y la capa prescriptiva transforma estos resultados en escenarios de precio y simulaciones de mejoras. La solución no pretende sustituir una tasación oficial ni garantizar un precio final de cierre.

A nivel de datos, se integran anuncios inmobiliarios de Adondevivir y Urbania con series trimestrales del BCRP y paraderos oficiales de la ATU. El pipeline de Week 06 depuró 3,822 anuncios crudos hasta 3,128 registros aptos para análisis espacial y predicción, recuperó variables desde texto libre, controló outliers y agregó contexto urbano y temporal. La selección preliminar de modelos ya cuenta con evidencia empírica: HistGradientBoosting alcanzó MAPE de 15.93% y R^2 de 0.8236 en el conjunto de prueba frente a un baseline Dummy de 36.59% de MAPE.

Resultado de la primera fase: El proyecto ya dispone de una definición de producto estable, requerimientos documentados, datasets procesados, un EDA reproducible, selección de métodos analíticos y una propuesta de arquitectura y experiencia inicial. El foco de Weeks 8–15 será convertir estos componentes en un prototipo integrado y evaluable.

2. Definición revisada del problema, antecedentes y propuesta de valor

2.1. Problema

La pregunta central del producto es: ¿cómo puede un propietario determinar un precio de alquiler razonable y una estrategia de publicación utilizando información objetiva del mercado y las características de su inmueble?

Los portales inmobiliarios facilitan la publicación y búsqueda de propiedades, pero la decisión económica sigue recayendo en el propietario. Dos departamentos ubicados en el mismo distrito no necesariamente compiten entre sí: la superficie, distribución, antigüedad, amenidades, conectividad y contexto de mercado pueden diferenciar de forma sustancial su posicionamiento.

DepaRent busca reducir esta incertidumbre transformando datos dispersos en información accionable. El sistema integra comparables, accesibilidad, valoración predictiva, tendencia distrital y escenarios de decisión dentro de una experiencia web centrada en el propietario.

2.2. Propuesta de valor

Situación actual	Propuesta DepaRent	Valor para el propietario
Comparación manual de anuncios	Segmentación y recuperación de comparables dentro del perfil competitivo	Comparaciones más pertinentes y contextualizadas
Precio fijado por intuición	Predicción del precio esperado con error medido	Referencia cuantitativa antes de publicar

Situación actual	Propuesta DepaRent	Valor para el propietario
Poca lectura del contexto distrital	Forecasting sobre series BCRP	Contexto sobre dirección del mercado
Decisión única y rígida	Escenarios competitivo, equilibrado y de renta superior	Elección alineada con el objetivo del propietario
Dudas sobre invertir en mejoras	Simulación contrafactual con el mismo modelo de precio	Evaluación previa de escenarios sin afirmar causalidad

Alcance responsable: Las salidas se comunican como estimaciones y escenarios de apoyo a la decisión. DepaRent no emite tasaciones oficiales, no garantiza el precio contractual final y no predice aún el tiempo exacto hasta alquilar.

3. Objetivos del producto

3.1. Objetivo general

Desarrollar una plataforma web de apoyo a la decisión para propietarios de departamentos en alquiler en Lima Metropolitana y Callao, que integre datos inmobiliarios y territoriales con técnicas descriptivas, predictivas y prescriptivas para analizar el posicionamiento del inmueble, estimar su precio esperado y generar escenarios que apoyen la definición de una estrategia de publicación.

3.2. Objetivos específicos

1. Caracterizar competitivamente cada inmueble e identificar propiedades comparables relevantes.
2. Evaluar el entorno de accesibilidad mediante información geográfica oficial de transporte público.
3. Desarrollar un modelo predictivo de precio de alquiler a partir de características físicas, de ubicación y contextuales.
4. Pronosticar la tendencia del mercado de alquiler por distrito utilizando series históricas inmobiliarias.
5. Generar escenarios prescriptivos de precio de publicación según el objetivo del propietario.
6. Implementar un simulador de mejoras que permita modificar virtualmente atributos seleccionados y observar cómo cambia el precio estimado.
7. Integrar en una única plataforma web la gestión y análisis de múltiples propiedades por propietario.

4. Data Product Canvas – primera fase

El Data Product Canvas de la primera fase resume la lógica de negocio, datos, actores y acciones del producto. La versión visual se entrega también como archivo independiente 'DataProductCanvas.pdf'.

Bloque Canvas	Definición consolidada
Problema	Incertidumbre del propietario para comparar su inmueble, estimar un precio razonable y definir una estrategia de publicación.
Usuario	Propietario de uno o varios departamentos en alquiler; como usuario secundario, persona que busca alquilar sin registro obligatorio en la primera versión.
Datos	Anuncios inmobiliarios; series BCRP; paraderos ATU; variables físicas, amenidades extraídas, ubicación, accesibilidad y contexto temporal.
Hipótesis	Integrar comparables, contexto urbano, precio esperado y tendencia de mercado puede reducir la incertidumbre de posicionamiento del propietario.
Solución	Plataforma web con seis funcionalidades: perfil competitivo, accesibilidad, predicción de precio, pronóstico distrital, escenarios de precio y simulador de mejoras.

Bloque Canvas	Definición consolidada
Actores	Propietarios, potenciales inquilinos, agentes/inmobiliarias, equipo de desarrollo, equipo ML/Data, administrador de plataforma y proveedores de datos.
Métricas	Calidad y cobertura de datos; silhouette de clustering; MAE/RMSE/MAPE/R ² en precio; validación temporal en forecasting; criterios de aceptación y rendimiento de la aplicación.
Impacto	Centralizar el análisis previo a la publicación y convertir datos inmobiliarios/territoriales en una decisión de precio más informada.
Acciones	Registrar propiedad, analizar, comparar, interpretar contexto, elegir estrategia, simular mejoras y publicar.

5. Usuarios, stakeholders, necesidades y requerimientos

5.1. Usuarios objetivo

Usuario	Necesidad principal	Interacción esperada
Propietario (principal)	Valorar y posicionar uno o varios departamentos con apoyo de datos.	Registro/login, gestión de propiedades, análisis, simulación, definición de precio y publicación.
Persona que busca alquilar (secundario)	Explorar propiedades disponibles y contactar al propietario.	Consulta pública de inventario y ficha del inmueble sin registro obligatorio en MVP.
Agente/inmobiliaria	Gestionar portafolios y utilizar análisis comparativos.	Stakeholder secundario y potencial usuario B2B en etapas posteriores.

5.2. Stakeholders

- Propietarios de departamentos en alquiler.
- Personas que buscan alquilar.
- Agentes inmobiliarios e inmobiliarias.
- Equipo de desarrollo.
- Equipo de Machine Learning / Data.
- Administrador de la plataforma.
- Proveedores externos de datos: BCRP y ATU.

5.3. Requerimientos macro

ID	Requerimiento	Funcionalidades cubiertas
R1	Analizar y valorizar integralmente el inmueble para reducir la incertidumbre antes de definir una estrategia de publicación.	Perfil competitivo · Accesibilidad · Predicción de precio · Pronóstico distrital
R2	Utilizar los resultados del análisis y el objetivo del propietario para generar escenarios de precio y simulaciones antes de publicar.	Precio recomendado · Simulador de mejoras

5.4. Requisitos funcionales y no funcionales

Categoría	Síntesis
Gestión de usuario y propiedades	Registro/inicio de sesión, múltiples inmuebles por cuenta, edición, publicación y persistencia del análisis.
Analítica R1	Segmentación y comparables, indicadores de accesibilidad, estimación de precio y tendencia distrital.
Analítica R2	Escenarios de precio y simulación de atributos modificables sin alterar permanentemente la ficha original.
Cara pública	Inventario público, ficha de propiedad y contacto con el propietario.
No funcionales	Usabilidad, rendimiento objetivo <5 s para resultados ya calculables, seguridad, privacidad, explicabilidad, reproducibilidad, calidad de datos, escalabilidad y comunicación responsable.

Criterios de aceptación representativos: La cuenta debe administrar más de una propiedad; el sistema debe producir comparables, predicción de precio y tendencia cuando exista cobertura; debe diferenciar precio propuesto, estimado y limitaciones; y el simulador debe recalcular un escenario sin modificar permanentemente el inmueble original.

6. Datos disponibles y diccionario de datos

6.1. Fuentes y volumen

Fuente	Volumen actual	Contenido principal	Uso en DepaRent
Adondevivir Urbana	+ 3,822 anuncios crudos · 43 columnas	Precio, distrito, áreas, dormitorios, baños, coordenadas, texto libre y atributos del anuncio.	Base microinmobiliaria; clustering, comparables y predicción.
BCRP	663 observaciones trimestrales · 6 variables	PER, precio de venta USD/m ² , tipo de cambio y alquiler implícito por distrito.	Contexto temporal y forecasting distrital.
ATU	3,233 paraderos · 10 columnas	Paraderos georreferenciados, corredor, modalidad y afluencia.	Features de accesibilidad urbana.

Tras filtros geográficos, de precio, área y doble modalidad venta/alquiler, el dataset principal utilizado para análisis espacial y predicción queda en 3,128 departamentos. Para clustering se conserva además un dataset específico que preserva anuncios sin geolocalización cuando las variables requeridas están disponibles.

6.2. Diccionario de datos – familias de variables

Familia	Ejemplos	Tratamiento
Precio y mercado	precio_soles, precio_m2_real, mantenimiento	Estandarización, control de outliers e imputación documentada cuando corresponde.
Características físicas	area_total, area_construida, dormitorios, banos, medios_banos, antigüedad, piso	Validación de rangos, extracción desde texto e indicadores de missingness.
Estacionamiento	estacionamientos, cochera, estacionamientos_imputado	No asumir nulo = 0; la ausencia se conserva como información ambigua.
Amenidades	piscina, gimnasio, seguridad_24_7, coworking, balcon, terraza, pet_friendly, etc.	Extracción por palabras clave desde texto libre.

Familia	Ejemplos	Tratamiento
Ubicación	distrito_norm, latitud, longitud	Normalización categórica y validación geográfica.
Accesibilidad	dist_paradero_min_m, paraderos_300m/500m/1000m, dist_troncal_brt_m	Ingeniería espacial con cKDTree.
Contexto BCRP	PER, Precio_Venta_USD, Alquiler_Mensual_Soles, bcrp_es_promedio_general	Join por distrito/trimestre y flag para uso de promedio metropolitano.

El diccionario completo y actualizado se entrega como `data\_dictionary.csv`.

7. Preprocesamiento e ingeniería de características

El pipeline de Week 06 separa explícitamente adquisición, recuperación de información, limpieza, integración y modelado. Cada transformación quedó documentada en el notebook reproducible.

Etapas	Descripción	Salida
1. Carga	Lectura de los tres datasets crudos.	DataFrames originales y diagnóstico inicial.
2. Diagnóstico	Nulos, tipos, rangos y calidad de categorías.	Mapa de problemas y decisiones de tratamiento.
3. Recuperación	Expresiones regulares y palabras clave sobre texto libre.	Piso, antigüedad, estacionamientos, mantenimiento y amenidades recuperadas.
4. Filtro	Coordenadas inválidas, precios/áreas extremos y anuncios venta/alquiler.	`df_clean` con 3,128 registros.
5. Integración	Join BCRP y features espaciales ATU.	Contexto distrital y accesibilidad.
6. Modelado preliminar	Benchmark de regresión, clustering y diagnóstico temporal.	Métodos candidatos y selección de primera fase.

7.1. Recuperación desde texto libre

Variable	Registros recuperados	Cobertura ganada	Criterio
piso	2,098	54.89%	Patrones de nivel/piso; rango válido 1–45.
antigüedad	521	13.63%	Años declarados o “estreno” = 0.
estacionamientos	197	5.15%	Cocheras mencionadas explícitamente.
mantenimiento	43	1.13%	Cuotas en soles entre S/ 50 y S/ 2,500.

Las amenidades también se recuperan desde texto libre. Entre las de mayor prevalencia se encuentran seguridad 24/7 (44.6%), parrilla (37.6%), ascensor (36.1%), gimnasio (33.0%), balcón (31.9%) y coworking (30.3%).

7.2. Limpieza de outliers y registros no válidos

- Se descartaron 694 observaciones (18.16%) del dataset original.
- 127 anuncios correspondían a doble modalidad venta/alquiler; 40 de ellos habrían pasado un filtro solo por monto, por lo que se excluyeron también por texto del título.
- El precio se acotó al rango S/ 800–S/ 25,000 y el área total a 25–450 m², con inspección manual de casos extremos.

- Se corrigió “Barranca” a “Barranco” utilizando evidencia de coordenadas.
- 19 distritos con menos de 20 anuncios se agruparon como “Otros” para reducir categorías de muy baja frecuencia y riesgo de sobreajuste.

8. Análisis exploratorio de datos: hallazgos y limitaciones

8.1. Distribuciones y relaciones

Hallazgo	Evidencia	Implicación
Distribución de precio más estable	Skewness disminuye de 14.07 a 3.24 tras filtros.	Menor influencia de errores extremos en el entrenamiento.
Mediana de alquiler	S/ 2,750 en `df_clean`.	Referencia descriptiva central del mercado observado.
Variables lineales más asociadas al precio	mantenimiento $r=0.79$; area_total $r=0.77$; baños $r=0.50$.	Área y costos de mantenimiento contienen señal fuerte para valoración.
Accesibilidad aporta señal adicional	dist_paradero_min_m y dist_troncal_brt_m aparecen entre variables importantes en Random Forest.	El contexto urbano complementa características físicas.
Cobertura BCRP	83.7% de propiedades enlazan con serie distrital propia.	16.3% requiere promedio metropolitano y menor precisión contextual.

8.2. Accesibilidad urbana

- Distancia mediana al paradero más cercano: 174.8 m.
- 71.6% de departamentos tiene al menos un paradero a menos de 300 m.
- Promedio de 9.3 paraderos dentro de un radio de 500 m.
- Distancia mediana a la troncal del Metropolitano (BRT): 1,767.8 m.

8.3. Limitaciones que debe asumir el producto

Limitación	Efecto potencial	Tratamiento actual
Estacionamientos ambiguos	89.25% de nulos no permite distinguir “sin cochera” de “no informado”.	Preservar NaN y utilizar flag de missingness.
Amenidades y piso dependen de texto	Sinónimos no contemplados generan falsos negativos.	Diccionario de palabras clave y documentación de cobertura.
Cobertura BCRP incompleta	16.3% usa promedio metropolitano.	Flag `bcrp_es_promedio_general` y comunicación de menor precisión.
ATU con corte mayo 2021	Nueva infraestructura puede no estar reflejada.	Documentar antigüedad de la fuente y evitar afirmar actualidad absoluta.
Asking price $\neq$ contrato	El precio objetivo es oferta publicada, no cierre final.	Comunicar resultado como referencia de mercado, no tasación contractual.

9. Enfoque analítico, modelos seleccionados y baselines

La selección de primera fase distingue claramente cuándo se requiere Machine Learning y cuándo un método analítico más simple es suficiente. Esto evita introducir complejidad sin valor adicional para el producto.


#	Componente	Método seleccionado	Baseline / alternativa	Evidencia / criterio
1	Perfil competitivo	K-Means k=4 · 19 features estandarizadas · sin PCA	9 features + PCA, k=2: silhouette 0.274; 9 features sin PCA: 0.237	Modelo final silhouette 0.1647. Se prioriza interpretabilidad y riqueza de amenidades; se reconoce estructura débil y necesidad de validar estabilidad.
2	Accesibilidad urbana	Feature engineering geoespacial con cKDTree	No requiere modelo ML dedicado	Produce distancias y conteos; variables de transporte aportan señal al modelo de precio.
3	Precio esperado	HistGradientBoosting Regressor	Dummy mediana: MAPE 36.59%	MAPE 15.93%; R ² 0.8236; MAE S/501.48; RMSE S/853.70. Reduce 56.5% el error relativo frente al baseline.
4	Pronóstico distrital	SARIMA d=1, s=4	Naive estacional: mismo trimestre del año anterior	69.2% de las series BCRP no son estacionarias; estacionalidad trimestral justifica SARIMA.
5	Precio recomendado	Motor de reglas sobre outputs #1 + #3 + #4	No es un modelo ML nuevo	Genera escenarios competitivo, equilibrado y renta superior.
6	Simulador de mejoras	Inferencia contrafactual reutilizando #3	No requiere modelo adicional	Modifica virtualmente un atributo y compara predicción actual vs. simulada; no se interpreta como causalidad.

9.1. Benchmark del modelo de precio

Modelo	R ²	MAE (S/)	RMSE (S/)	MAPE
HistGradientBoosting	0.8236	501.48	853.70	15.93%
Random Forest	0.7889	500.87	933.92	16.05%
Gradient Boosting	0.7882	518.86	935.53	16.37%
KNN	0.7903	535.40	930.80	17.27%
Ridge	0.7787	622.36	956.28	21.56%
Dummy – mediana	-0.0689	1,213.26	2,101.61	36.59%


10. Arquitectura inicial del producto

La arquitectura inicial separa la experiencia web, la persistencia/orquestación y la capa analítica. Esta separación permite que los modelos evolucionen sin rediseñar por completo la interfaz del producto.



El backend deberá exponer servicios para registrar propiedades, solicitar análisis, recuperar resultados y persistir la estrategia seleccionada. La capa analítica utilizará datasets procesados y artefactos de modelo versionados. Las fuentes externas se integran mediante pipelines de actualización, no mediante llamadas directas desde el frontend.

11. Workflow del sistema




El workflow reúne los dos requerimientos macro. R1 culmina en el dashboard integral con perfil competitivo, accesibilidad, precio esperado y tendencia distrital. R2 utiliza estos outputs para generar escenarios de precio, ejecutar simulaciones y permitir que el propietario elija una estrategia de publicación.


12. Interfaz y wireframes de baja fidelidad

Los wireframes integradores representan la experiencia del propietario y concentran las seis funcionalidades en dos pantallas principales. Las versiones completas, casos de uso, storyboards e historias de usuario se mantienen en `Requirements.pdf`.

12.1. Wireframe R1 – Análisis integral



12.2. Wireframe R2 – Estrategia y simulación



13. Plan priorizado de implementación hasta Week 15

El siguiente plan prioriza primero la robustez del pipeline y los modelos centrales, luego la integración de los módulos prescriptivos y finalmente la validación del prototipo. Es un plan de ejecución propuesto para la segunda fase y puede ajustarse según la retroalimentación docente y los resultados técnicos.

Semana	Prioridad	Trabajo principal	Resultado esperado
Week 7	Alta	Consolidar definición integrada, arquitectura, requirements, datos y plan de implementación.	Delivery 1 completo y repositorio reorganizado.
Week 8	Alta	Estabilizar pipeline de datos, esquemas y artefactos procesados; pruebas de reproducibilidad.	Pipeline reproducible y datasets versionados.
Week 9	Alta	Validar estabilidad de K-Means $k=4$ e implementar segunda etapa de comparables (k-NN dentro de cluster + ubicación).	Perfil competitivo utilizable en producto.
Week 10	Alta	Tuning y análisis de error del HistGradientBoosting; definición de contrato de inferencia.	Modelo de precio versionado y endpoint/prototipo de inferencia.
Week 11	Media-Alta	Implementar/validar SARIMA temporal y consolidar módulo de accesibilidad.	Tendencia distrital y accesibilidad integrables.
Week 12	Alta	Construir motor de escenarios de precio y simulador contrafactual con advertencias de uso.	Módulos prescriptivos funcionales.
Week 13	Alta	Integrar frontend, backend, persistencia y modelos; flujo propietario de extremo a extremo.	Prototipo integrado.
Week 14	Alta	Pruebas con usuarios, criterios de aceptación, QA, rendimiento, revisión de explicabilidad y limitaciones.	Versión candidata final con hallazgos de validación.
Week 15	Alta	Evaluación final, documentación, limpieza de repositorio, presentación y entrega.	Prototipo final y Delivery 2.

14. División de responsabilidades

La asignación se alinea con los roles ya definidos por el equipo. Las actividades de integración, validación y presentación permanecen como responsabilidad compartida.

Integrante	Rol base	Responsabilidades Weeks 7–15
Adrian Urbina Mendoza	Team Leader / Data Acquisition & Preprocessing	Coordinación técnica; adquisición y limpieza; reproducibilidad; versionado de datasets; soporte a clustering/comparables; control del calendario y entregables.
Armando Martinez Palomino	Data Engineering & External Data Integration	Integración BCRP/ATU; diseño de esquemas y pipelines; backend/servicios de datos; soporte a arquitectura e integración del prototipo.
Breysi Salazar Medina	Machine Learning Engineer	Clustering y validación; modelo de precio y tuning; forecasting SARIMA; motor de escenarios y simulador; métricas y documentación de modelos.
Luciana Yangali Cáceres	Application / Visualization	Diseño y desarrollo de interfaz; dashboards; wireframes/prototipo; visualización de resultados; integración UX y pruebas de uso.
Todo el equipo	Integración y validación	Criterios de aceptación, pruebas de extremo a extremo, documentación final, revisión de limitaciones y presentación.

15. Conclusiones de primera fase

- DepaRent tiene una definición de problema y propuesta de valor estable: apoyar al propietario antes de fijar y publicar un alquiler, sin sustituir una tasación oficial.
- La combinación de datos microinmobiliarios con BCRP y ATU permite describir el inmueble, incorporar contexto urbano/temporal y construir variables útiles para predicción.
- El EDA reveló problemas reales de calidad —nulos estructurales, anuncios mixtos venta/alquiler, categorías raras y dependencia de texto libre— y estableció tratamientos explícitos y reproducibles.
- El modelo de precio HistGradientBoosting ya supera ampliamente el baseline, mientras que clustering y forecasting requieren validaciones adicionales antes de considerarse cerrados.
- La arquitectura de producto evita forzar Machine Learning donde no es necesario: accesibilidad usa feature engineering espacial, y los módulos prescriptivos reutilizan outputs existentes.
- La segunda fase debe concentrarse en robustecer los modelos pendientes, integrar la experiencia web completa y validar el prototipo con usuarios y criterios de aceptación.

Cierre: La primera fase demuestra que DepaRent es viable como Producto de Datos: existe un problema definido, usuarios y requerimientos claros, fuentes procesables, señal predictiva medible y una arquitectura inicial para convertir los análisis en decisiones de publicación.

16. Referencias y trazabilidad del repositorio

16.1. Artefactos base consolidados

Artefacto	Ruta / función
ProjectProposal.pdf / .docx	deliveries/week05/ — definición, antecedentes, usuarios, propuesta y alcance.
DataProductCanvas.pdf	deliveries/week05/ — Canvas de la primera fase.

Artefacto	Ruta / función
Requirements.pdf	deliveries/week05/ — stakeholders, necesidades, RF/RNF, criterios, casos de uso, wireframes, storyboards y user stories.
DataAnalysis.md	deliveries/week06/ — calidad de datos, preprocesamiento, EDA, hallazgos y limitaciones.
ModelSelection.md	deliveries/week06/ — métodos seleccionados, benchmarks, baselines y pendientes.
EDA_week06_v5.ipynb	deliveries/week06/code/ — notebook reproducible con limpieza, feature engineering y modelado preliminar.
data_dictionary.csv	deliveries/week06/ — catálogo actualizado de variables crudas y derivadas.
data/processed/	deliveries/week06/ — cinco datasets procesados utilizados en el análisis.

16.2. Fuentes externas de datos

- Adondevivir y Urbana — anuncios inmobiliarios de departamentos en alquiler.
- Banco Central de Reserva del Perú (BCRP) — series trimestrales del mercado inmobiliario.
- Autoridad de Transporte Urbano para Lima y Callao (ATU) — inventario georreferenciado de paraderos.

Repositorio público del proyecto: <https://github.com/Luciana-y/DepaRent>